

Отчёт: прогноз продаж Favorita

1. Какая задача была

Нужно было предсказать дневные продажи (`unit_sales`) для сети магазинов Corporación Favorita (Эквадор). Это задача является классической задачей регрессии на временных рядах — внутренние: с промо, выходными, праздниками, и по классике - ценами на нефть и другими внешними факторами.

Гипотезы

H1: ML и DL модели, использующие экзогенные признаки и лаговые/скользящие фичи, дадут **значительный прирост** качества прогноза относительно простых временных бейзлайнов (Naive, SeasonalNaive, ETS, Theta).

Критерий значительного прироста: снижение RMSLE **не менее чем на 20%** относительно лучшего бейзлайна на том же уровне агрегации.

H2: для табличных данных с категориальными признаками градиентный бустинг (CatBoost) покажет **лучший результат**, чем рекуррентная нейросеть (LSTM).

2. Данные

Источник данных

Датасет Favorita Grocery Sales Forecasting из Kaggle. Содержит ежедневные продажи товаров в магазинах Эквадора за 2013–2017 гг.

Модели строятся и валидируются на подвыборке

Полный датасет — это ~125 млн строк. Чтобы загрузить его в память, нужно много оперативной памяти. В моём случае локально это реализовать не получилось, полный датасет физически не влезал — падал то на этапе merge, то на этапе создания фичей.

Поэтому была взята репрезентативная подвыборка:

- **10 магазинов** — не случайный выбор, а **топ 10** (`store_nbr` 1–10). Выбор был мотивирован следующей логикой: эти магазины есть во всех периодах и покрывают разные типы (от крупных сетевых до небольших магазинчиков).
- **2000 самых продаваемых товаров** — внутри магазинов по частоте появления в train датасете. Тоы по количеству записей, чтобы в данных было достаточно наблюдений для обучения моделей.
- **2013–2017** — берём все годы для информативности, позже делим на тест и трейн.

Получилось ~21.7 млн строк. В целом разнообразие и ключевые свойства датасета (сезонность, промо, праздники, разнообразие товаров) были сохранены.

EDA

1.Распределение продаж наблюдается ярко выраженная правосторонняя асимметрия: много значений близких к нулю, но есть редкие крупные продажи - нужно сгладить такие выбросы. Так,


стандартное логарифмическое преобразование $\log_{10}$ делает распределение почти похожим на нормальное — сможем использовать метрику RMSLE и обучать модели на лог-таргете.

2.Сезонность стандартно ярко выражена на срезах дней недели: ВС и СБ дают примерно в 1.5 раза больше продаж, чем четверг. Сезонность по срезам месяцев заметно слабее (небольшие пики: март, сентябрь, декабрь).


3.Промо-акции — фактор с сильной предсказываемой силой: самое простое - средние продажи с промо 13.4 против 8.4 без промо (разница почти 60%), плюс промо чаще всего активируются в СР и ПТ.

4.Продажи неравномерны между магазинами: сильная разница, например самый топ-магазин (№3) продаёт почти в 4 раза больше анти топа (№10).


Графики (базовые результаты EDA)




Средние продажи по дням недели




Средние продажи по месяцам




Общий тренд продаж по дням




Средние продажи по годам




Средние продажи: без промо vs промо



Доля промо по дням недели





3. Работа с моделями

Процесс валидации

Используется разбивка по времени для логики, специфичной для анализа временных рядов:

Набор	Период	Назначение
Train	2013-01-01 → 2016-12-31	обучение
Val	2017-01-01 → 2017-08-15	валидация
Test	2017-08-16 → 2017-08-31	Kaggle submission

То есть имитация рабочей задачи, где модель учится на прошлом/настоящем и пытается предсказывать будущее.

Главная метрика

RMSLE - Root Mean Squared Logarithmic Error: Формула: $\text{RMSLE} = \sqrt{\text{mean}((\log_{10}(y_{\text{pred}}) - \log_{10}(y_{\text{true}}))^2)}$

- предложена соревнованием Kaggle
- устойчива к выбросам
- хорошо предсказывает лог-нормальному распределению продаж

4. Модели

4.1. Бейзлайны

- **Naive**: прогноз = последнее наблюденное значение ряда.
- **SeasonalNaive**: прогноз = значение того же дня неделя к неделе. Предсказуемо оказался лучшим из простых бейзлайнов, тк данным свойственна недельная сезонность
- **auto.ets** (statsmodels): экспоненциальное сглаживание.
- **auto.theta** (statsmodels): Theta-метод с периодом 7.

Бейзлайны изначально считались на агрегированном ряду — все суммарные продажи по дням. Это упрощение, но оно проверяет склонность к недельной сезонности данных.

4.2. ML-модель: CatBoost

CatBoost — градиентный бустинг на решающих деревьях, хорошо работающий с категориальными признаками без энкодеров.

Таргет: `log1p(unit_sales)` — стабилизирует выявленный разброс в датасете.

Признаки - внешние и основные для временных рядов, 35:

- Идентификаторы: `store_nbr`, `item_nbr`, `family`, `city`, `state`, `type`, `cluster`, `class`, `perishable`.
- Промо: `onpromotion`, `promo_count_store`, `promo_ratio_store`.
- Внешние: `oil`, `is_holiday`, `transactions`.
- Временные: `dayofweek`, `month`, `day`, `year`, `weekofyear`, `dayofyear`, `sin/cos`.
- Лаги: 1, 7, 14, 28 дней назад.
- Скользящие: среднее/стандартное отклонение за 7, 30, 90 дней (со сдвигом на 1 день).

Два варианта. Сначала была запущена быстрая версия, чтобы проверить пайплайн, потом — полная:

Версия	Train	depth	iterations	subsample	Время	RMSLE
Быстрая	5 млн	6	300	0.5	~28 мин	0.4736
Полная	10 млн	8	1500	0.8	~4 часа	0.4677

Изменённые параметры полной версии:

- `iterations=1500`, `learning_rate=0.05`, `depth=8`
- `subsample=0.8`, `bootstrap_type=Bernoulli`
- `od_wait=50` (ранняя остановка если модель не улучшается)
- `save_snapshot=True` — пришлось поставить страховку от сбоя (каждые 100 итераций)

Быстрая версия нужна была для отладки и понимания применимости архитектуры модели в целом: проверить фиши, метрики, пайплайн - чтобы примерно понимать, куда двигаться дальше. Увеличение train с 5 до 10 млн и depth с 6 до 8 дало **+0.006** к RMSLE. Однако прирост скромный — модель почти вышла на плато, а во времени работы разница довольно значительная.

4.3. DL-модель: LSTM

LSTM (Long Short-Term Memory) — рекуррентная нейросеть, обрабатывающая последовательность последних 30 дней для каждой пары наблюдений (магазин, товар).

Признаки (25): промо, oil (forward fill), holidays, transactions, временные фиши из МЛ, категориальные коды.

Архитектура:

- 2 слоя LSTM (hidden=64) → Dropout(0.2) → Linear(1).
- Loss: MSE в log-пространстве.

- Optimizer: Adam ($lr=5e-4$), gradient clipping.

Предобработка для обучения: forward fill для oil, StandardScaler (z-score), единая подвыборка пар для train/val.

Два запуска:

Версия	Пар	Эпох	Dropout	Early stopping	RMSLE
v1 (базовая)	500	3	нет	нет	0.6002
v2 (полная)	2000	10	0.2	да	0.6054

В v1 модель переобучалась — train_mse падал, val_rmsle рос. В режиме настройки параметров были добавлены dropout и early stopping во v2, но качество даже немного упало (0.6054 vs 0.6002). Значит LSTM в этой задаче **не переобучалась критично** и регуляризация была лишней.

5. Что получилось в итоге

5.1. Бейзлайны на агрегированном ряду

Модель	RMSLE
SeasonalNaive	0.2519
auto.theta	0.2819
Naive	0.3009
auto.ets	0.3157

Вывод: Здесь и далее выбор был в пользу SeasonalNaive — сильнейший бейзлайн из предложенных. Для разумного дльнейшего сравнения на store-item уровне метрика пересчитана - **0.7883**

5.2. ML-модель: CatBoost

Модель	RMSLE (store-item уровень)
SeasonalNaive	0.7883
CatBoost (быстрая)	0.4736
CatBoost (полная)	0.4677
Прирост vs SeasonalNaive	-41%

Вывод: CatBoost существенно превосходит бейзлайн. Быстрая версия, практически как и полная (разница 0.006), но дольше в 4 раза. Если бы ресурсы были ограничены сильнее, можно было бы остановиться на быстрой версии и не терять почти ничего в качестве.

Feature Importance (Top-15)

Фича	Важность (%)
roll_mean_30	27.02
roll_mean_7	14.94
roll_mean_90	11.15
transactions	6.37
lag_1	4.52
dayofweek	3.93
dow_sin	3.60
lag_7	3.24
lag_14	3.07
day	2.28
item_nbr	2.22
oil	2.03
store_nbr	1.87
dow_cos	1.58
class	1.48

Вывод: Топ-3 признака - roll_mean 30/7/90 - суммарно дают **53% Importance**.

5.3. DL-модель: LSTM

Модель	Уровень	RMSLE
SeasonalNaive	store-item	0.7883
LSTM v1	store-item	0.6002
LSTM v2	store-item	0.6054
CatBoost (полная)	store-item	0.4677

Сравнение динамики по эпохам (модели ДЛ v2):

Эпоха	val_rmsle
1	0.6633
3	0.6372
5	0.6245
7 (лучшая)	0.6054
8	0.6100

Эпоха	val_rmsle
9	0.6092

Вывод:

- модель LSTM **превосходит бейзлайн на 23%** (0.7883 против 0.6054).
- при этом **уступает CatBoost** (0.4677 против 0.6054) на 23%. это подтверждается скопом применимости моделей для табличных данных с категориальными признаками градиентный бустинг обычно сильнее RNN.
- ранний stopping сработал на лучшей эпохе 7.

5.4. Анализ ошибок CatBoost**Ошибки в срезе промо vs без промо:**

Категория	RMSLE
Без промо	0.4611
Промо	0.5209

В промо-дни модель ошибается на 13% сильнее.

Распределение residuals близко к нормальному, концентрируется вокруг 0.

Ошибки по срезу магазины варьируются в диапазоне 0.456–0.484 (разброс около 6%).

5.5. Kaggle Submission

Финальный submission отправлен в соревнование Kaggle

Предложенный формат сдачи - 3 370 464 строки, колонки **id**, **unit_sales**. Файл загружен как **submission.zip**. Выбросы **unit_sales > 100** так как kaggle ругался на них.

Финальный результат Kaggle:

Метрика	Значение
Public Score (RMSLE)	1.03390
Private Score (RMSLE)	1.01482
Статус	Complete

Однако Kaggle-score в 2 раза ожидаемо хуже локальной валидации получился. На валидации (10 магазинов на 2000 товаров) CatBoost показал RMSLE = 0.4677, а на полном Kaggle-тесте — 1.0339.

Основных причин две:

1. Получается, что 90% пар наблюдений (магазин, товар) в test не встречались в обучении. Соответственно для них модель не видела лагов и rolling-средних, которые, исходя из анализа

важности признаков, составляют 53% важности фичей. Предсказания «вслепую» с опорой только на день недели и промо портят метрику.

2. Разброс магазинов всё равно очень сильный, подвыборка не отражает все-все типы магазинов. В test — все 54 магазина, а в обучении были только 10. Если модель не видела магазин, она предсказывает среднее по всем увиденным, а это плохо, особенно для крайних случаев.

Исправить можно и нужно, обучая на всех 54 магазинах и 4100 товарах. Соответственно не локально, используя например ноутбуки в Google Colab / самом Kaggle Notebooks

6. Что получилось в итоге

Результаты

Модель	Тип	RMSLE (store-item)
SeasonalNaive	бейзлайн	0.7883
LSTM	DL	0.6054
CatBoost (полная)	ML	0.4677
Kaggle Public Score	—	1.03390

Проверка гипотез

H1: подтверждена. Лучший бейзлайн -SeasonalNaive - на store-item уровне дал RMSLE = 0.7883. CatBoost — **0.4677**. Это **–41% ошибок** — намного больше порога в 20%, который был заложен в критерий. Значит, экзогенные признаки действительно дают прирост качества предсказания.

H2: подтверждена. CatBoost (МЛ) = 0.4677, LSTM (ДЛ) = 0.6054. CatBoost **выигрывает на 23%** — как и предполаглось для табличных данных с категориальными признаками.

Что дало наибольший прирост:

1. переход от бейзлайна к ML
2. использование Rolling-средних (30/7/90 дней)
3. внешние признаки (oil, holidays, transactions)

Что НЕ дало прироста

1. Dropout в LSTM

Основные ограничения

1. **Подвыборка** (10 магазинов × 2000 товаров из 54 × 4100) обусловлена локальными вычислениями
2. **Промо-всплески** — основная ошибка CatBoost (RMSLE 0.52 в промо-дни vs 0.46 без)

Направления дальнейших улучшений

1. Использование полного датасета для более корректной валидации
2. Промо базированные фичи, например лаги промо, типы промо, длительность акций

3. TFT (Temporal Fusion Transformer) на GPU вместо LSTM

7. Скриншоты

Kaggle Submissions:

🔍 Search

CORPORACIÓN FAVORITA · FEATURED PREDICTION COMPETITION · 9 YEARS AGO

Late Submission

...

Corporación Favorita Grocery Sales Forecasting

Can you accurately predict sales for a large grocery chain?



Overview

Data

Code

Models

Discussion

Leaderboard

Rules

Team

Submissions

Leaderboard

⬇️ Raw Data

🔄 Refresh

YOUR RECENT SUBMISSION

📁 submission.zip

Submitted by Tatiana Vasileva · Submitted 3 hours ago

Score: 1.01482

Public score: 1.03390

⬇️ Jump to your leaderboard position

🔍 Search leaderboard

Public

Private

The private leaderboard is calculated with approximately 69% of the test data.

GitHub-репозиторий:

10 / 11

TS_HSE_HW3

Public

Pin

Watch 0

Fork 0

Star 0

main1 Branch0 Tags

Go to fileT

Add file

Code

Tatiana Update README and requirementsctde8fa · 1 hour ago5 Commits

results	Add analysis notebook	2 hours ago
src	Initial commit: Favorita HW3	3 hours ago
submissions	Add final results: LSTM, Kaggle, conclusions	2 hours ago
.gitignore	Update .gitignore: add submissions/	2 hours ago
README.MD	Initial commit: Favorita HW3	3 hours ago
requirements.txt	Update README and requirements	1 hour ago

README

TS HSE 2025-2026 HW3: Favorita Sales Forecasting

Описание

Прогнозирование ежедневных продаж сети магазинов Corporación Favorita с использованием экзогенных признаков.

Структура

- `src/` — основной код
- `data/` — данные
- `results/` — результаты экспериментов
- `submissions/` — файлы для Kaggle

Установка

```
python -m venv venv venv\Scripts\activate pip install -r requirements.txt
```

Запуск

```
python src/run_experiment.py
```

Метрика

RMSLE (Root Mean Squared Logarithmic Error) — как в соревновании Kaggle.

About

Favorita Sales Forecasting — HW3

Readme

Activity

0 stars

0 watching

0 forks

Releases

No releases published

Create a new release

Packages

No packages published

Publish your first package

Contributors

No contributors

Languages

Jupyter Notebook 75.1%

Python 24.9%

Suggested workflows

Based on your tech stack

Publish Python Package

Configure

Publish a Python Package to PyPI on release.

By GitHub Actions

Python package

Configure

Create and test a Python package on multiple Python versions.

By GitHub Actions

Django

Configure

Build and Test a Django Project

By GitHub Actions

More workflows

11 / 11