

Отчёт: Favorita Sales Forecasting

1. Постановка задачи и гипотеза

Прогнозирование ежедневных продаж (unit_sales) для сети магазинов Corporación Favorita (Эквадор).
Задача — регрессия на временных рядах с множеством внешних факторов (промо, праздники, цены на нефть).

Гипотеза: переход от простых временных моделей к ML и DL моделям, использующим экзогенные признаки, даёт значительный прирост качества прогноза.

2. Описание данных

Источник

Датасет Favorita Grocery Sales Forecasting (Kaggle). Содержит ежедневные продажи товаров в магазинах Эквадора за 2013–2017.

Подвыборка

В связи с ограничениями вычислительных ресурсов (полный датасет ~125 млн строк, требует >30 ГБ RAM) эксперименты проводились на репрезентативной подвыборке: 10 магазинов (из 54), 2000 самых продаваемых товаров (из 4100), период 2013–2017, 21.7 млн строк.

EDA (разведочный анализ)

Распределение продаж имеет ярко выраженную правостороннюю асимметрию: большинство значений близки к нулю, но есть редкие крупные продажи. Логарифмическое преобразование $\log_{10}$ делает распределение почти нормальным — это обосновывает использование метрики RMSLE и обучение моделей на логарифмированной цели.

Сезонность выражена на уровне дней недели: воскресенье и суббота дают в ~1.5 раза больше продаж, чем четверг. Сезонность по месяцам слабее (пики март, сентябрь, декабрь).

Промо-акции — сильный предиктор: средние продажи с промо 13.4 против 8.4 без промо (+59%). Промо чаще всего активируются в среду и пятницу.

Продажи неравномерны между магазинами: топ-магазин (№3) продаёт в 4 раза больше аутсайдера (№10).

Графики

- results/01_sales_distribution.png
- results/02_seasonality.png
- results/03_promo_effect.png
- results/04_top_stores_items.png

3. Методология эксперимента

Протокол валидации

Используется hold-out по времени (не случайное разбиение — это критично для временных рядов):

Набор	Период	Назначение
Train	2013-01-01 → 2016-12-31	обучение
Val	2017-01-01 → 2017-08-15	валидация
Test	2017-08-16 → 2017-08-31	Kaggle submission

Такое разбиение имитирует реальную задачу: модель учится на прошлом и предсказывает будущее.

Метрика

RMSLE (Root Mean Squared Logarithmic Error):

$$\text{RMSLE} = \sqrt{\text{mean}((\log_{10}(y_{\text{pred}}) - \log_{10}(y_{\text{true}}))^2)}$$

- Совпадает с метрикой соревнования Kaggle.
- Устойчива к выбросам (log-преобразование сжимает большие значения).
- Хорошо соответствует лог-нормальному распределению продаж (см. EDA).

Обоснование подвыборки

Полный датасет — 125 млн строк, требует >30 ГБ RAM. Подвыборка: 10 магазинов × 2000 товаров × 2013–2017 = 21.7 млн строк. Сохраняет все ключевые свойства: сезонность, промо, праздники, экзогенные признаки, разнообразие товаров.

4. Описание моделей

4.1. Бейзлайны

- **Naive**: прогноз = последнее наблюденное значение ряда.
- **SeasonalNaive**: прогноз = значение того же дня недели неделю назад (season=7). Лучший из простых бейзлайнов.
- **auto.ets** (statsmodels): экспоненциальное сглаживание.
- **auto.theta** (statsmodels): Theta-метод с периодом 7.

Бейзлайны считались на **агрегированном ряду** — суммарные продажи по дням. Это упрощение, но оно даёт точку отсчёта и показывает, что продажи имеют сильную недельную сезонность.

4.2. ML-модель: CatBoost

CatBoost — градиентный бустинг на решающих деревьях, хорошо работающий с категориальными признаками без one-hot encoding.

Целевая переменная: `log1p(unit_sales)` — соответствует метрике RMSLE и стабилизирует дисперсию.

Признаки (35 шт):

- Идентификаторы: `store_nbr`, `item_nbr`, `family`, `city`, `state`, `type`, `cluster`, `class`, `perishable`.
- Промо: `onpromotion`, `promo_count_store`, `promo_ratio_store`.
- Внешние: `oil`, `is_holiday`, `transactions`.
- Временные: `dayofweek`, `month`, `day`, `year`, `weekofyear`, `dayofyear`, `sin/cos`.
- Лаги: 1, 7, 14, 28 дней назад.
- Скользящие: `mean/std` за 7, 30, 90 дней (со сдвигом на 1 день).

Гиперпараметры (полная версия):

- `iterations=1500`, `learning_rate=0.05`, `depth=8`
- `subsample=0.8`, `bootstrap_type=Bernoulli`
- `od_wait=50` (ранняя остановка)
- `save_snapshot=True` — защита от сбоя (каждые 100 итераций)

Время обучения: ~4 часа (10 млн строк train, полная валидация).

4.3. DL-модель: LSTM

LSTM (Long Short-Term Memory) — рекуррентная нейросеть, обрабатывающая последовательность последних 30 дней для каждой пары (магазин, товар).

Признаки (25): промо, oil (forward fill), holidays, transactions, временные фичи, категориальные коды.

Архитектура:

- 2 слоя LSTM (`hidden=64`) → Dropout(0.2) → Linear(1).
- Loss: MSE в log-пространстве.
- Optimizer: Adam (`lr=5e-4`), gradient clipping.

Препроцессинг: forward fill для oil, StandardScaler (z-score), единая подвыборка пар для train/val.

5. Результаты

5.1. Бейзлайны (агрегированный ряд)

Модель	RMSLE
SeasonalNaive	0.2519
auto.theta	0.2819
Naive	0.3009
auto.ets	0.3157

Вывод: SeasonalNaive — сильнейший бейзлайн.

5.2. ML-модель: CatBoost (уровень store-item)

Модель	RMSLE (store-item)
SeasonalNaive	0.7883
CatBoost (полная)	0.4677
Прирост vs SeasonalNaive	−41%

Вывод: CatBoost существенно превосходит бейзлайн.

Feature Importance (Top-15)

Фича	Важность (%)
roll_mean_30	27.02
roll_mean_7	14.94
roll_mean_90	11.15
transactions	6.37
lag_1	4.52
dayofweek	3.93
dow_sin	3.60
lag_7	3.24
lag_14	3.07
day	2.28
item_nbr	2.22
oil	2.03
store_nbr	1.87
dow_cos	1.58
class	1.48

Топ-3 (roll_mean 30/7/90) дают 53% важности.

5.3. DL-модель: LSTM

Модель	Уровень	RMSLE
SeasonalNaive	store-item	0.7883
LSTM	store-item	0.6054
CatBoost (полная)	store-item	0.4677

Сравнение по эпохам:

Эпоха	val_rmsle
1	0.6633
3	0.6372
5	0.6245
7 (лучшая)	0.6054
8	0.6100
9	0.6092

Вывод:

- LSTM **превосходит бейзлайн на 23%** (0.7883 → 0.6054).
- Но **уступает CatBoost** (0.4677 vs 0.6054) на 23%. Это ожидаемо: для табличных данных с категориальными признаками градиентный бустинг обычно сильнее RNN при обучении на CPU.
- Early stopping сработал корректно: лучшая эпоха — 7-я.

5.4. Анализ ошибок CatBoost

Ошибки в промо vs без промо:

Категория	RMSLE
Без промо	0.4611
Промо	0.5209

В промо-дни модель ошибается на 13% сильнее.

Распределение остатков близко к нормальному с центром около 0.

Ошибки по магазинам варьируются в диапазоне 0.456–0.484 (разброс ~6%).

5.5. Kaggle Submission

Финальный submission отправлен в соревнование Kaggle (вкладка Late Submission, лимит 100/день).

Формат: 3 370 464 строки, колонки `id`, `unit_sales`. Файл загружен как `submission.zip` (96 МБ → 28 МБ в архиве). Выбросы `unit_sales > 100` обрезаны (203 значения).

Результат:

Метрика	Значение
Public Score (RMSLE)	1.03390
Private Score (RMSLE)	1.01482
Статус	Complete

Обсуждение разницы с валидацией. На валидации (10 магазинов × 2000 товаров) CatBoost показал RMSLE = 0.4677. На полном Kaggle-тесте — 1.0339.

Причина: **90% пар в test не встречались в обучении.** Модель для них «слепая». Это **ожидаемое поведение** при работе на подвыборке. Для полного датасета необходимо обучать модель на всех 54 магазинах и 4100 товарах.

6. Выводы

Основные результаты

Модель	Тип	RMSLE (store-item)
SeasonalNaive	бейзлайн	0.7883
LSTM	DL	0.6054
CatBoost (полная)	ML	0.4677
Kaggle Public Score	—	1.03390

Гипотеза подтверждена: переход от простых временных моделей к ML и DL с экзогенными признаками дал значительный прирост качества (−41% RMSLE vs бейзлайн).

Что дало наибольший прирост

1. **Переход от бейзлайна к ML** (−41% ошибки) — решающий скачок.
2. **Rolling-средние (30/7/90 дней)** — 53% важности фичей.
3. **Экзогенные признаки** (промо, oil, holidays, transactions) дали положительный вклад; oil вошёл в топ-15.

Что НЕ дало прироста

1. **Dropout в LSTM** — регуляризация не помогла, LSTM и так не переобучалась критично.
2. **Промо-фичи** не вошли в топ-15 важности CatBoost — эффект перекрывается лагами и rolling-средними.

Ограничения

1. **Подвыборка** (10 магазинов × 2000 товаров из 54 × 4100) обусловлена 16 ГБ RAM.
2. **Обучение на CPU** ограничило DL-модель.
3. **Промо-всплески** — основная ошибка CatBoost (RMSLE 0.52 в промо-дни vs 0.46 без).
4. **Kaggle score (1.03) хуже валидации (0.47)** из-за невидимых в обучении пар.

Направления улучшения

1. **Полный датасет** — прямой путь к снижению Kaggle RMSLE в ~2 раза.
2. **Промо-фичи:** лаги промо, типы промо, длительность акций.
3. **Ансамбль CatBoost + LSTM** — усреднение прогнозов.
4. **TFT** (Temporal Fusion Transformer) на GPU вместо LSTM.