

Отчёт: Favorita Sales Forecasting

1. Постановка задачи и гипотеза

Прогнозирование ежедневных продаж (`unit_sales`) для сети магазинов Corporación Favorita (Эквадор).
Задача — регрессия на временных рядах с множеством внешних факторов (промо, праздники, цены на нефть).

Гипотеза: переход от простых временных моделей к ML и DL моделям, использующим экзогенные признаки, даёт значительный прирост качества прогноза.

2. Описание данных

Источник

Датасет Favorita Grocery Sales Forecasting (Kaggle). Содержит ежедневные продажи товаров в магазинах Эквадора за 2013–2017.

Подвыборка

В связи с ограничениями вычислительных ресурсов (полный датасет ~125 млн строк, требует >30 ГБ RAM) эксперименты проводились на репрезентативной подвыборке: 10 магазинов (из 54), 2000 самых продаваемых товаров (из 4100), период 2013–2017, 21.7 млн строк.

EDA (разведочный анализ)




Распределение продаж имеет ярко выраженную правостороннюю асимметрию: большинство значений близки к нулю, но есть редкие крупные продажи. Логарифмическое преобразование $\log_{10}$ делает распределение почти нормальным — это обосновывает использование метрики RMSLE и обучение моделей на логарифмированной цели.


Сезонность выражена на уровне дней недели: воскресенье и суббота дают в ~1.5 раза больше продаж, чем четверг. Сезонность по месяцам слабее (пики март, сентябрь, декабрь).

Промо-акции — сильный предиктор: средние продажи с промо 13.4 против 8.4 без промо (+59%). Промо чаще всего активируются в среду и пятницу.

Продажи неравномерны между магазинами: топ-магазин (№3) продаёт в 4 раза больше аутсайдера (№10).

Графики





3. Методология эксперимента

Протокол валидации

Используется hold-out по времени (не случайное разбиение — это критично для временных рядов):

Набор	Период	Назначение
Train	2013-01-01 → 2016-12-31	обучение
Val	2017-01-01 → 2017-08-15	валидация
Test	2017-08-16 → 2017-08-31	Kaggle submission

Такое разбиение имитирует реальную задачу: модель учится на прошлом и предсказывает будущее.

Метрика

RMSLE (Root Mean Squared Logarithmic Error):

$$\text{RMSLE} = \sqrt{\text{mean}((\log_{10}(\hat{y}) - \log_{10}(y_{\text{true}}))^2)}$$

- Совпадает с метрикой соревнования Kaggle.
- Устойчива к выбросам (лог-преобразование сжимает большие значения).
- Хорошо соответствует лог-нормальному распределению продаж (см. EDA).

Обоснование подвыборки

Полный датасет — 125 млн строк, требует >30 ГБ RAM. Подвыборка: 10 магазинов × 2000 товаров × 2013–2017 = 21.7 млн строк. Сохраняет все ключевые свойства: сезонность, промо, праздники, экзогенные признаки, разнообразие товаров.

4. Описание моделей

4.1. Бейзлайны

- **Naive**: прогноз = последнее наблюденное значение ряда.

- **SeasonalNaive**: прогноз = значение того же дня недели неделю назад (season=7). Лучший из простых бейзлайнов.
- **auto.ets** (statsmodels): экспоненциальное сглаживание.
- **auto.theta** (statsmodels): Theta-метод с периодом 7.

Бейзлайны считались на **агрегированном ряду** — суммарные продажи по дням. Это упрощение, но оно даёт точку отсчёта и показывает, что продажи имеют сильную недельную сезонность.

4.2. ML-модель: CatBoost

CatBoost — градиентный бустинг на решающих деревьях, хорошо работающий с категориальными признаками без one-hot encoding.

Целевая переменная: `log1p(unit_sales)` — соответствует метрике RMSLE и стабилизирует дисперсию.

Признаки (35 шт):

- Идентификаторы: `store_nbr`, `item_nbr`, `family`, `city`, `state`, `type`, `cluster`, `class`, `perishable`.
- Промо: `onpromotion`, `promo_count_store`, `promo_ratio_store`.
- Внешние: `oil`, `is_holiday`, `transactions`.
- Временные: `dayofweek`, `month`, `day`, `year`, `weekofyear`, `dayofyear`, sin/cos.
- Лаги: 1, 7, 14, 28 дней назад.
- Скользящие: mean/std за 7, 30, 90 дней (со сдвигом на 1 день).

Гиперпараметры (полная версия):

- `iterations=1500`, `learning_rate=0.05`, `depth=8`
- `subsample=0.8`, `bootstrap_type=Bernoulli`
- `od_wait=50` (ранняя остановка)
- `save_snapshot=True` — защита от сбоя (каждые 100 итераций)

Время обучения: ~4 часа (10 млн строк train, полная валидация).

4.3. DL-модель: LSTM

LSTM (Long Short-Term Memory) — рекуррентная нейросеть, обрабатывающая последовательность последних 30 дней для каждой пары (магазин, товар).

Признаки (25): промо, oil (forward fill), holidays, transactions, временные фичи, категориальные коды.

Архитектура:

- 2 слоя LSTM (hidden=64) → Dropout(0.2) → Linear(1).
- Loss: MSE в log-пространстве.
- Optimizer: Adam (lr=5e-4), gradient clipping.

Преобработка: forward fill для oil, StandardScaler (z-score), единая подвыборка пар для train/val.

5. Результаты

5.1. Бейзлайны (агрегированный ряд)

Модель	RMSLE
SeasonalNaive	0.2519
auto.theta	0.2819
Naive	0.3009
auto.ets	0.3157

Вывод: SeasonalNaive — сильнейший бейзлайн.

5.2. ML-модель: CatBoost (уровень store-item)

Модель	RMSLE (store-item)
SeasonalNaive	0.7883
CatBoost (полная)	0.4677
Прирост vs SeasonalNaive	–41%

Вывод: CatBoost существенно превосходит бейзлайн.

Feature Importance (Top-15)

Фича	Важность (%)
roll_mean_30	27.02
roll_mean_7	14.94
roll_mean_90	11.15
transactions	6.37
lag_1	4.52
dayofweek	3.93
dow_sin	3.60
lag_7	3.24
lag_14	3.07
day	2.28
item_nbr	2.22
oil	2.03
store_nbr	1.87
dow_cos	1.58

Фича	Важность (%)
class	1.48

Топ-3 (roll_mean 30/7/90) дают 53% важности.

5.3. DL-модель: LSTM

Модель	Уровень	RMSLE
SeasonalNaive	store-item	0.7883
LSTM	store-item	0.6054
CatBoost (полная)	store-item	0.4677

Сравнение по эпохам:

Эпоха	val_rmsle
1	0.6633
3	0.6372
5	0.6245
7 (лучшая)	0.6054
8	0.6100
9	0.6092

Вывод:

- LSTM **превосходит бейзлайн на 23%** (0.7883 → 0.6054).
- Но **уступает CatBoost** (0.4677 vs 0.6054) на 23%. Это ожидаемо: для табличных данных с категориальными признаками градиентный бустинг обычно сильнее RNN при обучении на CPU.
- Early stopping сработал корректно: лучшая эпоха — 7-я.

5.4. Анализ ошибок CatBoost

Ошибки в промо vs без промо:

Категория	RMSLE
Без промо	0.4611
Промо	0.5209

В промо-дни модель ошибается на 13% сильнее.

Распределение остатков близко к нормальному с центром около 0.

Ошибки по магазинам варьируются в диапазоне 0.456–0.484 (разброс ~6%).

5.5. Kaggle Submission

Финальный submission отправлен в соревнование Kaggle (вкладка Late Submission, лимит 100/день).

Формат: 3 370 464 строки, колонки `id`, `unit_sales`. Файл загружен как `submission.zip` (96 МБ → 28 МБ в архиве). Выбросы `unit_sales > 100` обрезаны (203 значения).

Результат:

Метрика	Значение
Public Score (RMSLE)	1.03390
Private Score (RMSLE)	1.01482
Статус	Complete

Обсуждение разницы с валидацией. На валидации (10 магазинов × 2000 товаров) CatBoost показал RMSLE = 0.4677. На полном Kaggle-тесте — 1.0339.

Причина: **90% пар в test не встречались в обучении**. Модель для них «слепая». Это **ожидаемое поведение** при работе на подвыборке. Для полного датасета необходимо обучать модель на всех 54 магазинах и 4100 товарах.

6. Выводы

Основные результаты

Модель	Тип	RMSLE (store-item)
SeasonalNaive	бейзлайн	0.7883
LSTM	DL	0.6054
CatBoost (полная)	ML	0.4677
Kaggle Public Score	—	1.03390

Гипотеза подтверждена: переход от простых временных моделей к ML и DL с экзогенными признаками дал значительный прирост качества (−41% RMSLE vs бейзлайн).

Что дало наибольший прирост

1. **Переход от бейзлайна к ML** (−41% ошибки) — решающий скачок.
2. **Rolling-средние (30/7/90 дней)** — 53% важности фичей.
3. **Экзогенные признаки** (промо, oil, holidays, transactions) дали положительный вклад; oil вошёл в топ-15.

Что НЕ дало прироста

1. **Dropout в LSTM** — регуляризация не помогла, LSTM и так не переобучалась критично.
2. **Промо-фичи** не вошли в топ-15 важности CatBoost — эффект перекрывается лагами и rolling-средними.

Ограничения

1. **Подвыборка** (10 магазинов × 2000 товаров из 54 × 4100) обусловлена 16 ГБ RAM.
2. **Обучение на CPU** ограничило DL-модель.
3. **Промо-всплески** — основная ошибка CatBoost (RMSLE 0.52 в промо-дни vs 0.46 без).
4. **Kaggle score (1.03) хуже валидации (0.47)** из-за невидимых в обучении пар.

Направления улучшения

1. **Полный датасет** — прямой путь к снижению Kaggle RMSLE в ~2 раза.
2. **Промо-фичи**: лаги промо, типы промо, длительность акций.
3. **Ансамбль CatBoost + LSTM** — усреднение прогнозов.
4. **TFT** (Temporal Fusion Transformer) на GPU вместо LSTM.

7. Скриншоты

Kaggle Submissions:

The screenshot displays the Kaggle competition page for 'Corporación Favorita Grocery Sales Forecasting'. At the top, there is a search bar and a 'Late Submission' button. The competition title is prominently displayed, followed by the question: 'Can you accurately predict sales for a large grocery chain?'. Below this, a navigation bar includes links for Overview, Data, Code, Models, Discussion, Leaderboard (which is currently selected), Rules, Team, and Submissions. The 'Leaderboard' section shows a 'YOUR RECENT SUBMISSION' box with a green checkmark icon, indicating a successful submission of 'submission.zip' by Tatiana Vasileva, submitted 3 hours ago. The submission score is 1.01482, and the public score is 1.03390. A button labeled 'Jump to your leaderboard position' is also visible. Below the submission box is a search bar for the leaderboard and tabs for 'Public' and 'Private' leaderboards. A note at the bottom states: 'The private leaderboard is calculated with approximately 69% of the test data.'

GitHub-репозиторий:

TS_HSE_HW3

Public

Pin

Watch 0

Fork 0

Star 0

main

1 Branch

0 Tags

Go to file

T

Add file

Code

Tatiana

Update README and requirements

ctde8fa · 1 hour ago

5 Commits

results	Add analysis notebook	2 hours ago
src	Initial commit: Favorita HW3	3 hours ago
submissions	Add final results: LSTM, Kaggle, conclusions	2 hours ago
.gitignore	Update .gitignore: add submissions/	2 hours ago
README.MD	Initial commit: Favorita HW3	3 hours ago
requirements.txt	Update README and requirements	1 hour ago

README

TS HSE 2025-2026 HW3: Favorita Sales Forecasting

Описание

Прогнозирование ежедневных продаж сети магазинов Corporación Favorita с использованием экзогенных признаков.

Структура

- src/ — основной код
- data/ — данные
- results/ — результаты экспериментов
- submissions/ — файлы для Kaggle

Установка

```
python -m venv venv venv\Scripts\activate pip install -r requirements.txt
```

Запуск

```
python src/run_experiment.py
```

Метрика

RMSLE (Root Mean Squared Logarithmic Error) — как в соревновании Kaggle.

About

Favorita Sales Forecasting — HW3

Readme

Activity

0 stars

0 watching

0 forks

Releases

No releases published

Create a new release

Packages

No packages published

Publish your first package

Contributors

No contributors

Languages

Jupyter Notebook 75.1%

Python 24.9%

Suggested workflows

Based on your tech stack

Publish Python Package

Configure

Publish a Python Package to PyPI on release.

By GitHub Actions

Python package

Configure

Create and test a Python package on multiple Python versions.

By GitHub Actions

Django

Configure

Build and Test a Django Project

By GitHub Actions

More workflows

X

9 / 9